

## PROPUESTA DE MONOGRAFÍA

<b>Título del proyecto</b>	Predicción del estado de salud de componentes críticos de vehículos de movilidad sostenible	
<b>Estudiante 1</b>		
<b>Nombres completos</b>	Daniel Fernando Acosta González	e-mail: dfernando.acosta@udea.edu.co
		GitHub: <a href="https://github.com/IngDanielAcosta">https://github.com/IngDanielAcosta</a>
<b>Nombre del asesor</b>	Olga Cecilia Úsuga Manco	e-mail: olga.usuga@udea.edu.co

### 1. Descripción del problema

Mientras el contexto mundial se enfoca en discusiones relativas al impacto ambiental de las actividades humanas, se hace fundamental buscar alternativas al uso de recursos energéticos no renovables y potenciar un uso sostenible de las energías renovables, involucrando, por ejemplo, el uso vehículos eléctricos como alternativa a aquellos de combustible fósil (Ding et al., 2017). En dicho contexto, autoridades gubernamentales de países desarrollados impulsan estrategias relativas al uso de vehículos eléctricos (VE) que van desde reducción de impuestos hasta subsidios de compra e incluso infraestructura de carga (Sanguesa et al., 2021). Por otra parte, la producción de vehículos eléctricos y, en especial las baterías de estos pueden generar afectaciones ambientales que deben tratarse a través de estrategias que mejoren la posibilidad de reciclaje y uso en segunda instancia, además de desarrollos tecnológicos enfocados en el seguimiento de la vida útil de las baterías (Harper et al., 2019). Las técnicas existentes de Machine Learning, proveen un entorno de amplias posibilidades enfocadas en la predicción de diferentes fenómenos. En este caso, se propone aplicar métodos de ML, modelos de regresión, en la estimación del estado de vida útil de la batería relacionando el SOH (State of health) o el RUL (Remaining useful life) (Hong et al., 2021) de un modelo de bicicleta eléctrica ajustando las relaciones entre factores relativos al desgaste de la batería y la influencia de factores externos como la temperatura ambiente y características de la vía.

### 2. Descripción del dataset

Presente el origen de los datos, relacione la dirección de URL para acceder a esta (si lo tienes) y una breve descripción del dataset indicando la volumetría del mismo (número de archivos, filas, columnas) y las columnas o información que contiene. Si el número de características es muy grande, ponga solo las que se considere más representativas para dar una idea de cómo es el dataset.

Investigadores del grupo ALIADO del proyecto “Modelos de predicción para el análisis de confiabilidad de sistemas que impactan la eficiencia energética en escenarios de movilidad sostenible” recolectaron información de 62 ciclos de carga y descarga de batería y motor de una bicicleta eléctrica para un total de 91.811 registros, a través del seguimiento de

pruebas sobre condiciones de tráfico real en una vía particular de la ciudad de Medellín. Estos 62 ciclos contienen información de corriente, voltaje, potencia y temperatura en la batería (4 características) y mediciones de estas variables al motor en sus 3 polos (12 características). Se recolectaron además la humedad ambiental y la temperatura ambiente (2 características). Por otra parte, se tiene información de la aceleración en 3 ejes (3 características) y la duración, distancia, velocidad máxima y velocidad media (4 características). También se conoce el peso del conductor (1 característica) y se determinó la vida útil restante de la batería. Esta información se recolectó a lo largo de un año.

Cada registro es un segundo de tiempo con la información capturada en los sensores usados.

### 3. Métricas de desempeño

De acuerdo con la literatura, puede resultar conveniente una métrica de desempeño como el error cuadrático medio (RMSE):

$$RMSE = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_i - \hat{y}_i)^2}$$

donde  $n$  representa el número de observaciones,  $y_i$  representa los valores observados y  $\hat{y}_i$  representa la estimación (Ćalasan et al., 2020).

En cuanto a la métrica de negocio, se espera que el modelo funcione como una alerta temprana al desgaste de la batería, teniendo en cuenta que esto puede proporcionar información sobre el período de garantía de la batería bajo ciertas condiciones, o sobre el desgaste sufrido.

### 4. Criterio de desempeño

Teniendo en cuenta que esta medida es relativa al resultado y se propone un RMSE que, en promedio, diste hasta 20% del valor observado, es decir,

$$\sum_{i=1}^n \frac{\left(\frac{RMSE}{y_i}\right)}{n} \leq 0,2$$

Se espera estimar el SOH o RUL en un 80% de los casos, como métrica de negocio, lo que está muy relacionado con la métrica de desempeño.

### 5. Referencias

Ćalasan, M., Abdel Aleem, S. H. E., & Zobaa, A. F. (2020). On the root mean square error (RMSE) calculation for parameter estimation of photovoltaic models: A novel

exact analytical solution based on Lambert W function. En Energy Conversion and Management (Vol. 210, p. 112716). Elsevier BV.  
<https://doi.org/10.1016/j.enconman.2020.112716>

Ding, N., Prasad, K., & Lie, T. T. (2017). The electric vehicle: a review. En International Journal of Electric and Hybrid Vehicles (Vol. 9, Issue 1, p. 49). Inderscience Publishers. <https://doi.org/10.1504/ijehv.2017.082816>

Harper, G., Sommerville, R., Kendrick, E., Driscoll, L., Slater, P., Stolkin, R., Walton, A., Christensen, P., Heidrich, O., Lambert, S., Abbott, A., Ryder, K., Gaines, L., & Anderson, P. (2019). Recycling lithium-ion batteries from electric vehicles. En Nature (Vol. 575, Issue 7781, pp. 75–86). Springer Science and Business Media LLC.  
<https://doi.org/10.1038/s41586-019-1682-5>

Hong, J., Wang, Z., Chen, W., Wang, L., Lin, P., & Qu, C. (2021). Online accurate state of health estimation for battery systems on real-world electric vehicles with variable driving conditions considered. En Journal of Cleaner Production (Vol. 294, p. 125814). Elsevier BV. <https://doi.org/10.1016/j.jclepro.2021.125814>